机器学习在临床肿瘤学中的应用

摘 要

机器学习（Machine Learning，ML），作为计算机科学的子领域，是人工智能领域的重要分支和实现方式。近些年来，随着人工智能（Artificial Intelligence，AI）的蓬勃发展，相应的机器学习方法也在不断完善、突破。并且随着当前临床医疗数据的数量、复杂性等有了爆炸式的增长，机器学习作为人工智能中用来挖掘数据关系的一项重要技术，在临床肿瘤学中越来越多地用于诊断癌症、预测患者预后和告知治疗计划。

本文将结合相关资料和文献，在课程内对机器学习介绍的基础上，更加详细地展示本人了解到的机器学习的相关知识，并在此基础上结合自己在相关科研项目中的进展和相关文献，介绍当前 ML 在临床肿瘤学领域的研究、应用进展，最后通过实际编写、调试一种深度学习模型--U-net 的过程，分享一些自己在模型训练中的总结和思考。

关键词：机器学习，深度学习，U-net，临床肿瘤学，人工智能

目 录

摘 要 II
1 机器学习概述 1
1.1 机器学习的方法 1
1.2 机器学习的分类 1
1.2.1 监督学习 1
1.2.2 无监督学习 2
1.2.3 强化学习 2
2 机器学习在临床肿瘤学中的应用 4
2.1 选择临床肿瘤学领域的原因 4
2.2 图像水平的肿瘤放射治疗方案选择 4
2.3 分子水平的肿瘤诊断 5
3 U-net 模型的实践与思考 7
3.1 数据处理 7
3.2 模型训练 7
3.3 模型评估 8
4 结语 9
参考文献 10

1　机器学习概述

1.1 机器学习的方法

“机器”，在当下的语境里，我们很容易地知道指代的就是计算机。那么“学习”一词要如何理解呢？Tom Mitchell 在 1997 年，对机器学习中的“学习”给出了一个经典的定义，即，对于某类任务 T 和性能度量 P，一个计算机程序被认为可以从经验 E 中学习是指通过经验 E 改进后，它在任务 T 上的性能度量 P 衡量的性能有所提升。与此同时，“学习”也可以用基本的数学语言表示：通过学习算法（learning algorithm）A，对数据集的 n 个样本进行观测，以最小化预测的期望风险为目标，在函数族{f(x,w)}中估计依赖关系，找到一个最优预测函数 $f(x,w_0)$的过程[2]。

由此可以得出，机器学习的方法主要有模型、学习准则和算法 3 个基本要素[1]。

模型，事实上隐含在数据集中，机器学习的目标即找出这种最优的映射关系，建立模型，同时保证能很好地应用到其他数据集上（即模型良好的泛化能力）。当给定一个数据集，实际上就已经给出了当前数据集模型的假说空间，即所有可能的输入-输出映射关系的集合。接下来便需要确定使用的学习准则或者选择准则从中得到最优的模型。

目前的学习准则主要有损失函数、经验风险最小化和期望风险最小化等学习准则。这些在课堂上老师都有所介绍，在此不再赘述。

有了模型和对应的学习准则后，便需要通过算法，将定义的规则和空间转换成计算机语言，输入计算机即机器中求解。最早的机器学习算法可以追溯到 20 世纪初，到今天为止，已经过去了 100 多年。从 1980 年机器学习称为一个独立的方向开始算起，到现在也已经过去了近 40 年。在这 100 多年中，经过一代又一代人的努力，诞生出了大量经典的方法。

基于以上机器学习方法的 3 个基本要素的概述，接下来将结合相关文献，根据学习过程中经验获取的不同，从监督学习、无监督学习、强化学习三个方面对目前机器学习领域的经典算法进行梳理。

1.2 机器学习的分类

课堂上已经详细介绍了监督学习和无监督学习两个方向的大部分经典算法，在此就不再赘述，主要梳理强化学习方向的相关算法。

1.2.1 监督学习

监督学习即通过对已经标注好的训练样本进行学习，通过学习样本细节和对应标签的映射关系得到一个模型。然后用这个模型进行预测。根据预测任务的数量可以分为分类算法（离散的类别值）和回归算法（连续的实数值）。

在机器学习的发展中，监督学习的相关算法发展如图 1 所示，接下来简要介绍其中几种上课没有介绍到的。

线性判别分析（LDA）[3]是一种监督学习的降维技术，通过寻找一个线性组合的特征，使得类间距离最大化，类内距离最小化，实现分类；贝叶斯分类器基于贝叶斯定理，贝叶斯

分类器假设特征之间相互独立，通过计算后验概率来进行分类；Logistic 回归[4]是一种预测二分类结果的概率模型，广泛应用于医学、社会科学和市场营销等领域；ID3，CART，C4.5 都是构建决策树的三种算法，通过树形结构做出决策。

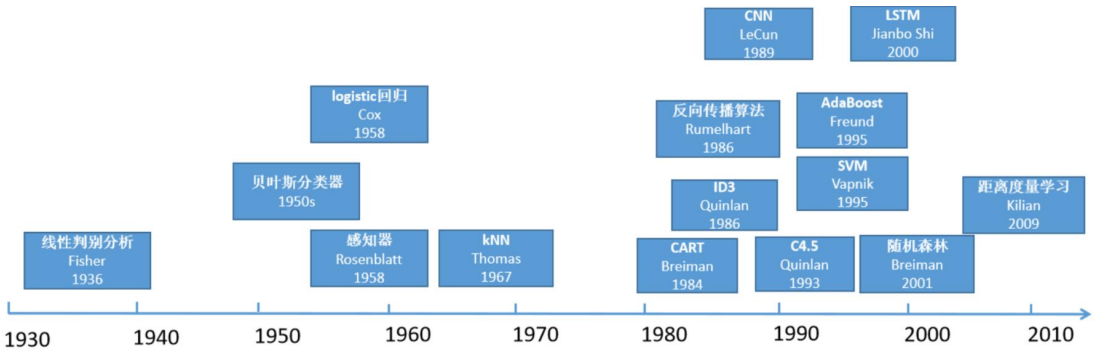

图 1.1 监督学习重要算法发展

1.2.2 无监督学习

无监督学习不同之处在于其学习的样本并没有人工标注的标签，需要让机器对数据的潜在关系进行分析，从而得到数据的一些潜在关系。因此无监督学习主要在聚类和特征降维两方面有所应用。值得一提的是，无监督学习的发展非常缓慢。

K-means[5]是最流行的聚类算法之一，通过迭代过程将数据点分配到 k 个聚类中，每个聚类由一个质心均值表示；谱聚类（Spectral Clustering）[6]是一种基于图论的聚类方法，它使用图的拉普拉斯变换来发现数据的低维表示，将聚类问题转化为图切割问题。

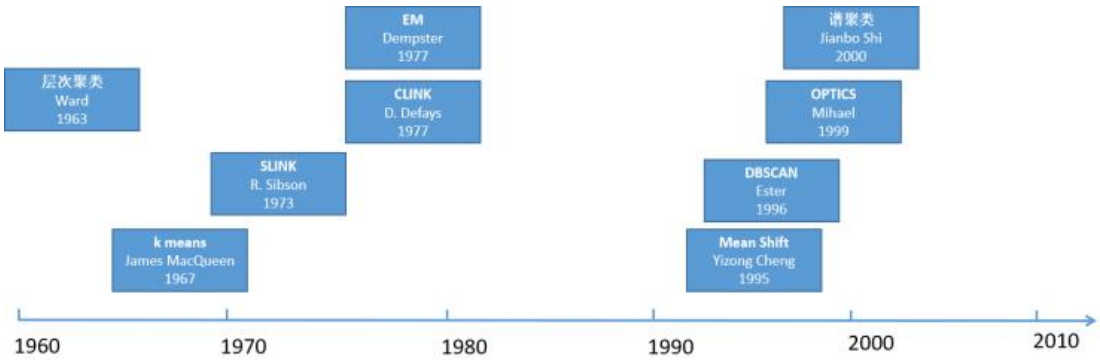

图 1.2 无监督学习重要算法发展

1.2.3 强化学习

强化学习是一种学习如何从状态映射到行为以使得获取的奖励最大的学习机制。通过环境给予的奖励来不断优化状态-行为的对应关系。与监督学习通过学习外界已经给定的标签来给其他数据给出一个“普适”的标签不同，强化学习的智能体只能从自身经验中去学习；与无监督学习从数据集中发现潜藏的数据关系不同，强化学习的智能体致力于得到最大化奖

励。因此，强化学习是除了监督学习、无监督学习之外的第三种机器学习范式。

Q-学习（Q-learning）是一种无模型的强化学习算法，通过学习一个动作价值函数 Q 函数，选择一个给定状态下具有最高 Q 值的行动，是基于价值的强化学习算法。与之类似的还有 Deep Q Network（DQN）算法。

如果忽略中间计算采取每个动作的价值的步骤，直接根据当前状态来选择动作，就是强化学习中的另一种重要算法-策略梯度（Policy Gradient，PG）。策略梯度不通过误差反向传播，而是通过观测信息选出一个行为直接进行反向传播，利用 reward 奖励直接对选择行为的可能性进行增强和减弱，好的行为会被增加下一次被选中的概率，不好的行为会被减弱下次被选中的概率。蒙特卡洛策略梯度（REINFORCE）是经典的算法。

强化学习主要分为基于策略和基于价值两大类，当然不乏一些既基于策略也基于价值的算法。无论如何，强化学习强调基于自身经验从与环境交互中进行学习，这种模式是机器学习中最接近人类思考学习的方式，是机器学习中最符合人工智能发展目标的方法。

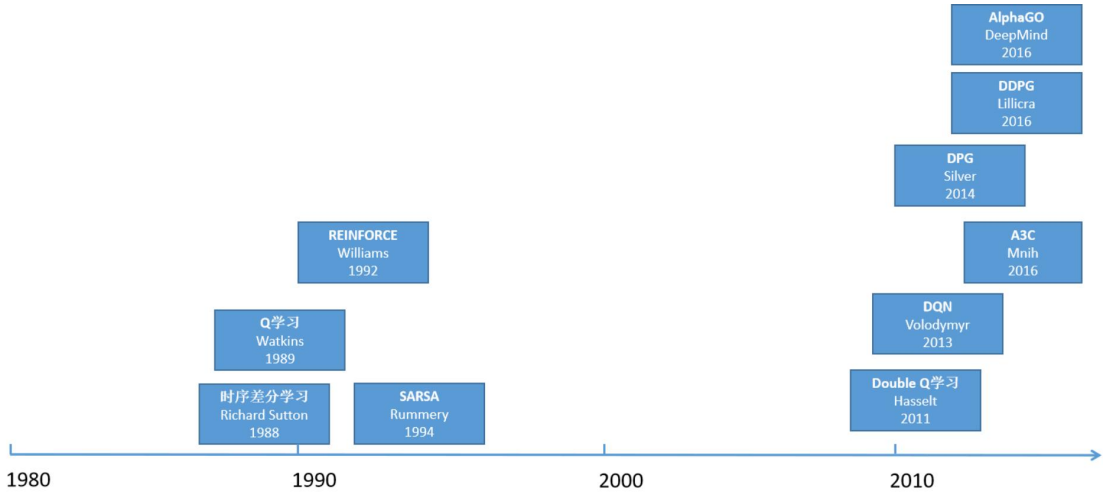

图 1.3 强化学习重要算法发展

2　机器学习在临床肿瘤学中的应用

2.1 选择临床肿瘤学领域的原因

在大二上学期，我接触了一项基于多模态深度学习的肺癌疗后反应预测的创新训练项目，在此过程中了解到了深度学习（即机器学习的子领域）在肿瘤诊断、预测与治疗方面的应用和研究，正好趁此次报告的机会结合之前阅读的相关文献从图像水平、分子水平两方面总结一下当前 ML 在临床肿瘤学领域的应用。值得强调的是，目前为止，各种机器学习模型的结果只能辅助医生决策，并不能完全替代医生在临床诊断中的作用。

2.2 图像水平的肿瘤放射治疗方案选择

医学影像是临床肿瘤诊断、预测疗效和制定治疗方案的重要工具。医学影像包括放射学图像和病理学图像等，其中放射学图像以及其他图像模式用于肿瘤形状、性质的初步筛查和诊断[7]，组织样本的病理学图像用于确认癌症诊断并确定癌症亚型等预后因素[8]。随着医学成像在临床肿瘤学工作流程中发挥着越来越重要的作用，医学影像的数据量增长速度快于临床医生所能处理的速度[7]。因此有必要引入智能化的处理方法，以减少临床医生的工作量。

ML（主要是深度学习模型更多一些）模型可以在临床的肿瘤风险评估、肿瘤类型诊断、放射治疗方案的选择等多个阶段进行应用，在这里主要介绍 U-net 模型在规划放射治疗阶段的应用。

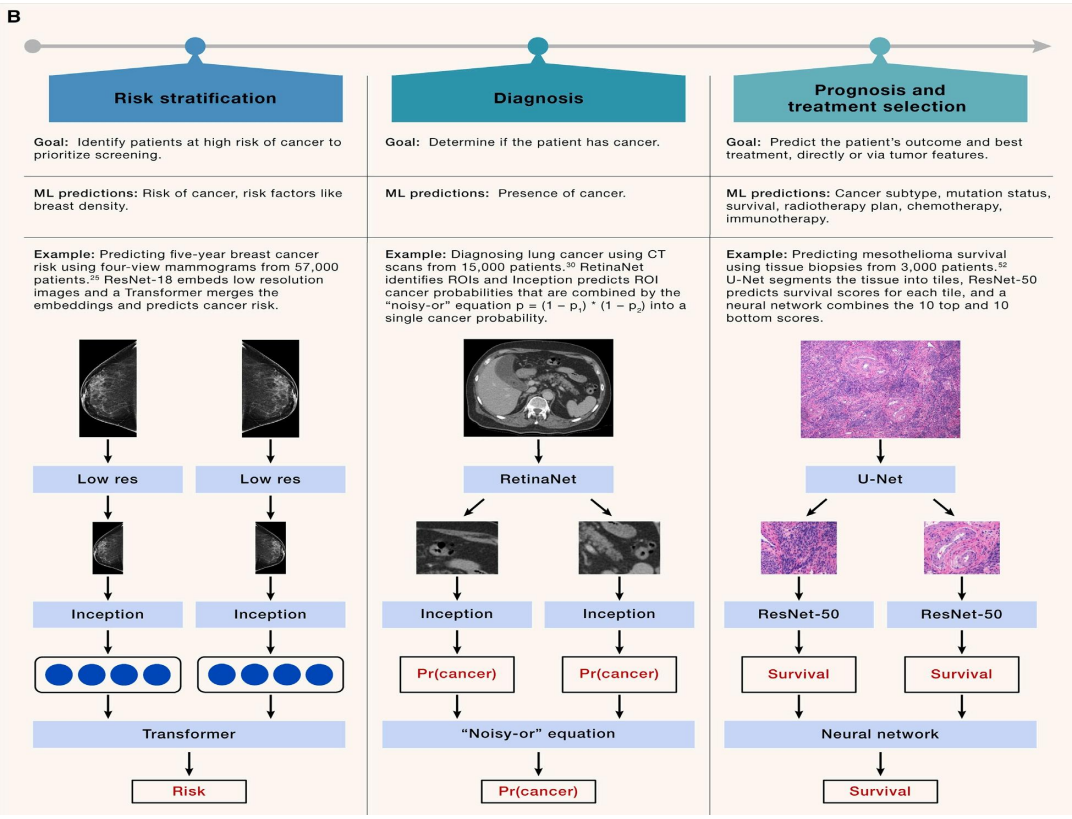

图 2.1 ML 模型在风险分层、诊断、治疗方案选择的应用

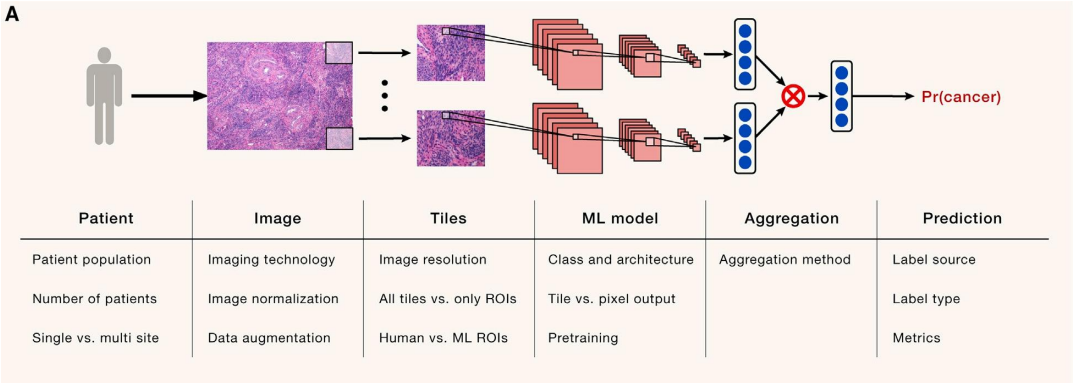

图 2.2 基于图像的 ML 模型处理流程

Hosny 等人曾建立一个 U-Net 模型来分割 CT 图像中的原发性非小细胞肺癌肿瘤和相关淋巴结，并在多个国家的八个内部和外部临床站点进行了验证[9]。在他们的研究中，人工智能模型的辅助使分割时间减少了 65%，临床医生之间决策的不一致性减少了 32%。

在美国，大多数机器学习算法都被食品和药物管理局（FDA）作为医疗设备进行监管。在过去的十年中，超过 300 种支持人工智能/机器学习的医疗设备获得了美国食品药品监督管理局的批准，其中 40%以上是自 2020 年以来获得批准的[10]。基于成像的算法占所有 FDA 批准的 AI/ML 设备的 70%以上。比如 AI-Rad Companion 和 Quantib Prostate 使用基于 CNN 的网络 U-Net 对前列腺癌进行自动分割、密度计算和体积估计[10]。

2.3 分子水平的肿瘤诊断

由于液体和固体肿瘤活检切片可以连续描述肿瘤状态，并识别与治疗耐药性、复发和低生存率结果相关的肿瘤演变和异质性特征[10]，因此借助 ML 有助于通过丰富的分子特征更加精确地预测临床结果和癌症状态。

分子水平的 ML 模型重点关注对基因组数据集的三级分析，可在肿瘤诊断、预后评估、肿瘤监测等临床阶段使用，在这里主要介绍在肿瘤诊断阶段的应用。

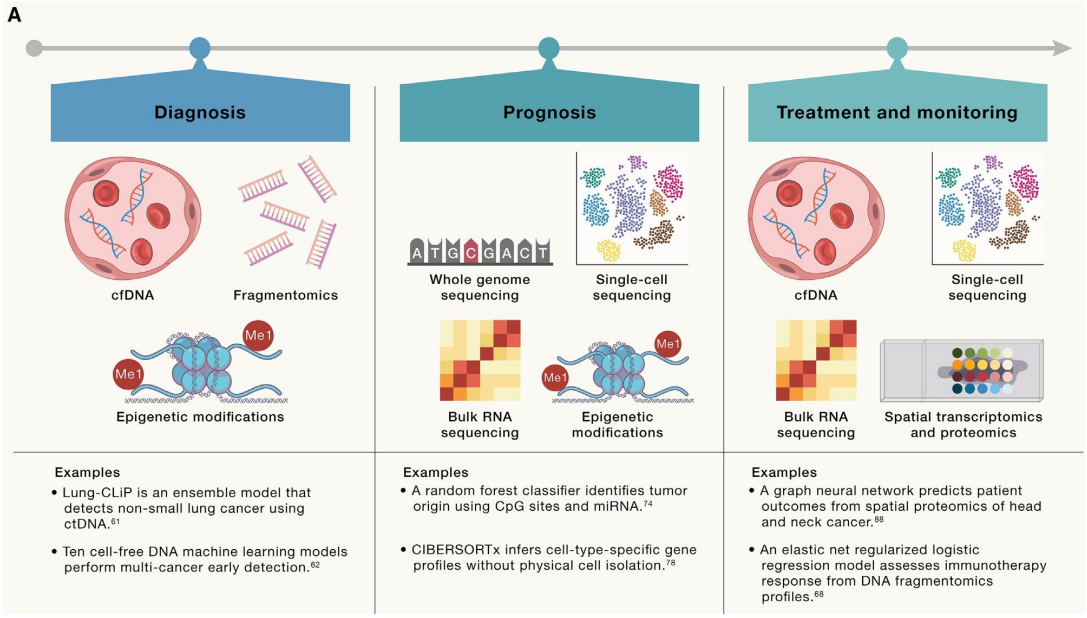

图 2.3 ML 模型在肿瘤诊断、预后评估、肿瘤监测的应用

目前大多数分子水平的算法都专注于血液样本。比如 Lung-CLiP（血浆中的癌症可能性）使用集合了近邻分类器、幼稚贝叶斯、逻辑回归和决策树的 ML 分类器，来确定血浆样品含有肺癌 ctDNA 的可能性[11]。FDA 批准的细胞计数设备，如 CellaVision 和 Sight OLO，使用细胞神经网络表征和计数血液样本中的白细胞、红细胞和血小板，供实验室技术人员使用[12]。

目前，随着机器学习技术的不断进步。基于结合不同数据模态（如医学影像、基因组学数据、临床记录等）的深度学习模型也在逐渐发展，以获得更全面的肿瘤信息。相信随着技术的进步，机器学习在临床肿瘤学中的应用有望进一步扩大，从而改善癌症的预测、诊断、治疗的时间成本。

3　U-net 模型的实践与思考

3.1 数据处理

处理数据使数据集符合模型的输入是非常重要的一步。我所实践的 U-net 模型是处理二维图像的模型，需要输入 png 文件。我主要处理使用了两个数据集。一个是我们指导老师合作的肺科医院那边传过来的患者肿瘤的 dcm 文件数据集，另一个则是 LUNA16 的公开数据集。

肺科医院的数据集是将一个 3D 的肺部 CT 影像数据沿 z 轴横向切成许多二维切片后组成的，需要将 dcm 文件转换成 png 格式，以符合模型的输入。并且需要根据 dcm 文件中的信息，提取每张切片的 mask 图像，并转换成 png 格式。在这一过程中，我学会了如何编写一个 python 程序，对原数据进行批处理的格式转换。

LUNA16 的公开数据集是 3D 的肺部结节 CT 图像，与我 2D 模型的输入不符，因此将 3D 的模型按照沿 z 轴横向切成许多二维切片的思路，转成二维的数据，并对其进行重采样，使其 spacing 像素间距统一。

3.2 模型训练

在训练过程中，我参考了 GitHub 上的开源 U-net 模型，通过 Carvana Image Masking Challenge 项目进行了学习，并基本掌握了 U-net 模型的复现框架。在配置好 Pytorch 环境后，我尝试将模型应用于肺科医院的数据集。但是在训练过程中，模型训练输出的 loss 值为 nan。通过查阅相关资料，这一异常现象可能是由于输入数据、模型输出或损失函数的数值范围不正确导致的。考虑到肺科医院数据集目前数据量小，又转向了使用 LUNA16 数据集。通过检查输入数据和掩码的范围，确保模型输出未经过 Sigmoid 处理直接传入 BCEWithLogitsLoss，降低学习率，添加梯度裁剪，以及确保掩码值正确归一化等方法，得到了一个训练好的模型。但是准确度堪忧，我觉得可能还需要后续进一步优化。

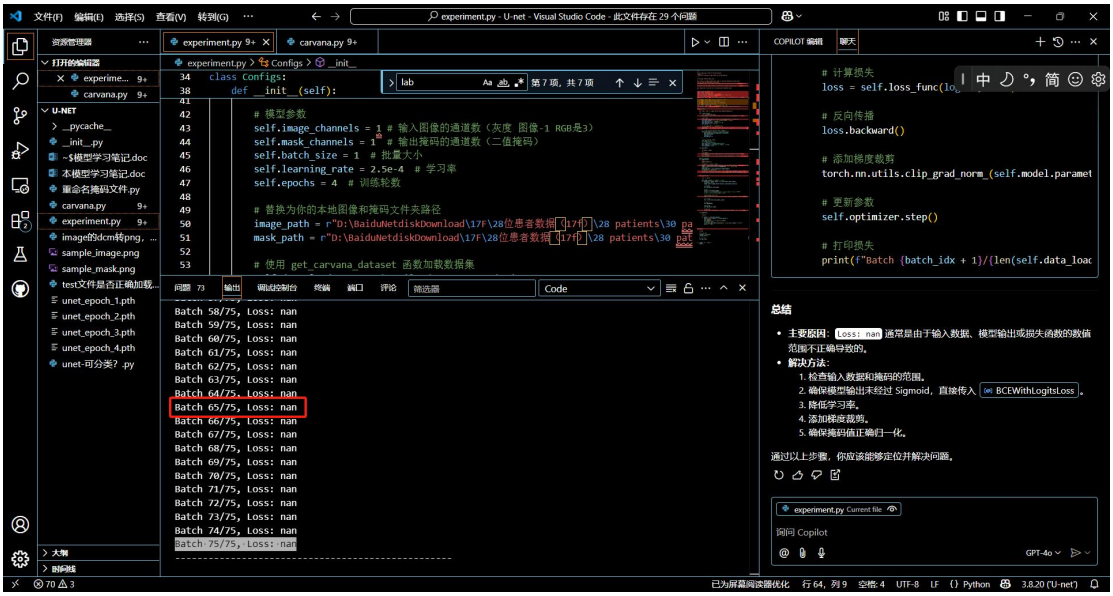

图 3.1 肺科医院数据集学习过程中遇到的 loss 值为 nan 的问题

3.3 模型评估

对于模型的评估，我使用了均方误差（MSE）、均方根误差(RMSE)、R 平方值(R2)来评估模型的预测性能。其实这些评估指标选择的不是太好，后续了解到还有 AUC，ROC 曲线，F1-Score 等其他更好的评价指标。这些指标我会在后续的 U-net 模型实践中逐步加入。目前 U-net 模型只能做到对比预测值和真实值的差距，输出一些模型评估指标的值，未能达到我们“预测”的目标，后续将继续修改模型的输出，比如将预测的数组转成预测的放疗后的体积，再在这个基础上修改一下数据加载的逻辑，使 U-net 模型去学习放疗前的 CT 图像+放疗后的肿瘤掩码 => 学习放疗前图像与放疗后掩码之间的映射关系,从而达到单一模态预测放疗后反应的目标。

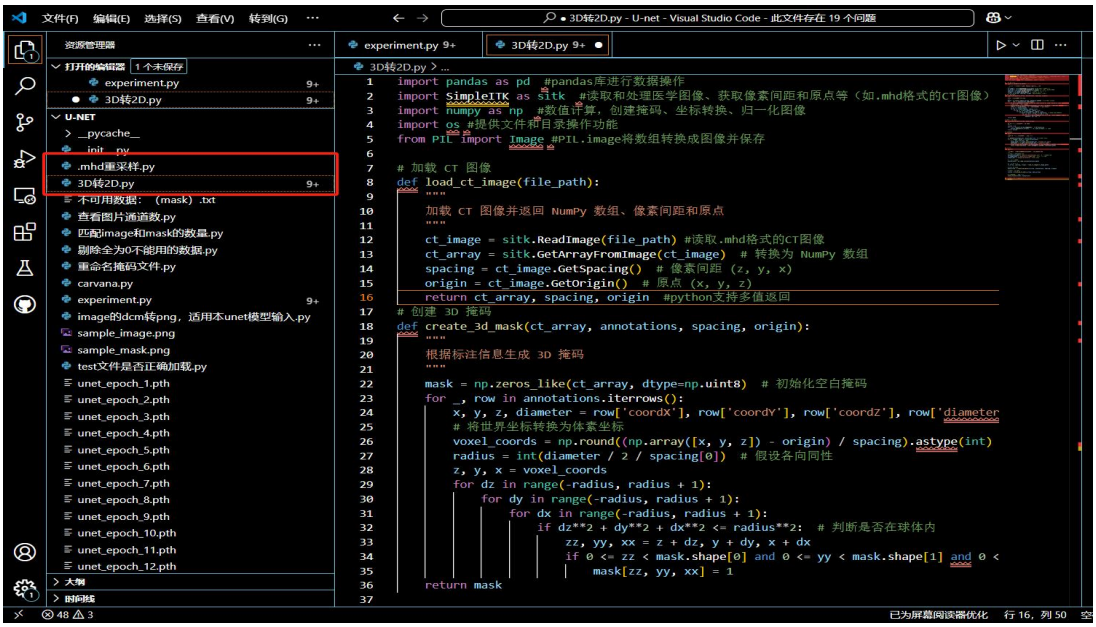

图 3.2 一些数据处理过程展示

4 结语

通过自己在实践一个深度学习模型（也算是机器学习的模型）的过程，再结合课程中老师的详细讲解，我深感自己对机器学习、深度学习领域的强烈兴趣。借此报告的机会，我又阅读和接触到了当前机器学习深度学习的发展和相关研究文献，梳理了机器学习的发展脉络、经典算法及其在临床肿瘤学领域的应用，坚定了我想要在这个方向进行进一步研究的想法，同时也意识到了将这些理论技术转化为临床实践中的挑战。

未来的工作需要在提高模型的准确性、可解释性以及临床适用性方面做出更多努力。此外，如何确保机器学习模型的公平性、透明度和患者隐私保护也是亟待解决的问题。相信未来的我们通过对这些挑战的深入思考和持续探索，机器学习在临床肿瘤学领域发挥更大的作用，为患者带来更好的治疗效果和生活质量。

参考文献

[1] 何思杰,刘庆芳,乔琛.数据建模中的机器学习方法[J].数学建模及其应用,2023,12(02):1-13.DOI:10.19943/j.2095-3070.jmmia.2023.02.01.

[2] Vermet F. Statistical learning methods[M. New York: John Wiley &. Sons, Ltd, 2018.

[3] Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. Annals of Eugenics. 7 (2): 179–188.

[4] Cox, DR (1958). The regression analysis of binary sequences (with discussion). J Roy Stat Soc B. 20 (2): 215–242.

[5] MacQueen, J. B. (1967). Some Methods for classification and Analysis of Multivariate Observations. Proceedings of 5th Berkeley Symposium on Mathematical Statistics and Probability. 1. University of California Press. pp. 281–297. MR 0214227. Zbl 0214.46201. Retrieved 2009-04-07.

[6] Jianbo Shi and Jitendra Malik, "Normalized Cuts and Image Segmentation", IEEE Transactions on PAMI, Vol. 22, No. 8, Aug 2000.

[7] Hosny, A., Parmar, C., Quackenbush, J., Schwartz, L.H., and Aerts, H.J.W.L. (2018). Artificial intelligence in radiology. Nat. Rev. Cancer 18, 500–510.

[8] Bera, K., Schalper, K.A., Rimm, D.L., Velcheti, V., and Madabhushi, A.(2019). Artificial intelligence in digital pathology - new tools for diagnosis and precision oncology. Nat. Rev. Clin. Oncol. 16, 703–715.

[9] Hosny, A., Bitterman, D.S., Guthier, C.V., Qian, J.M., Roberts, H., Perni, S., Saraf, A., Peng, L.C., Pashtan, I., Ye, Z., et al (2022). Clinical validation of deep learning algorithms for radiotherapy targeting of non-smallcell lung cancer: an observational study. Lancet. Digit. Health 4, e657–e666.

[10] Kyle Swanson, Eric Wu, Angela Zhang, Ash A. Alizadeh, James Zou(2023).From patterns to patients: Advances in clinical machine learning for cancer diagnosis, prognosis, and treatment,Cell,Volume 186, Issue 8.

[11] Chabon, J.J., Hamilton, E.G., Kurtz, D.M., Esfahani, M.S., Moding, E.J., Stehr, H., Schroers-Martin, J., Nabet, B.Y., Chen, B., Chaudhuri, A.A., et al (2020). Integrating genomic features for non-invasive early lung cancer detection. Nature 580, 245–251.

[12] Bachar, N., Benbassat, D., Brailovsky, D., Eshel, Y., Glu¨ ck, D., Levner, D., Levy, S., Pecker, S., Yurkovsky, E., Zait, A., et al (2021). An artificial intelligence-assisted diagnostic platform for rapid near-patient hematology. Am. J. Hematol. 96, 1264–1274.